UNIVERSIDAD DEL NORTE — PARAGUAY

Ingeniería Informática — Octavo Semestre

Datawarehouse (22891)

TRABAJO PRÁCTICO — 2.º SEMESTRE 2026

H2 — Avance Intermedio

Campo	Detalle
Organización	AgroExport Paraguay S.A. (empresa ficticia)
Docente	Lic. Walter Romero
Materia	Datawarehouse — 22891 — 8.º Semestre
Hito	H2 — Avance Intermedio
Fecha de elaboración	Octubre 2026
Modalidad	Individual
Repositorio Git	https://github.com/PedroSRM/agroexport-dw

1. Modelo Dimensional — Star Schema

El modelo dimensional de AgroExport Paraguay S.A. sigue el esquema estrella (star schema). La tabla de hechos central registra cada despacho de exportación como un evento atómico, rodeada de cuatro dimensiones que describen el contexto de ese evento.

1.1 Declaración del grano

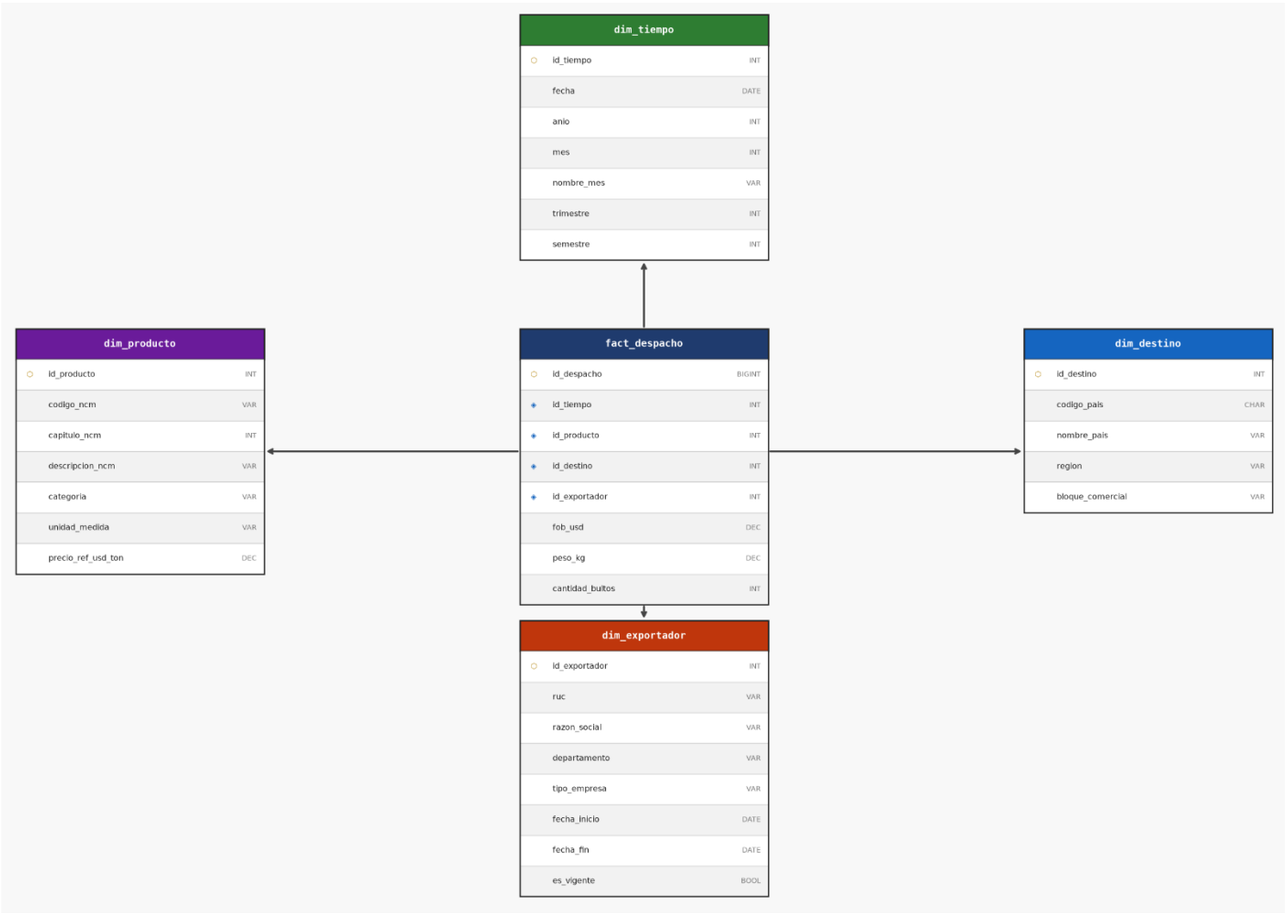
El grano de la tabla de hechos fact_despacho es: un registro por despacho de exportación individual. Esto significa que cada fila representa un único envío de mercadería, de un exportador, hacia un destino, en una fecha determinada, con un código NCM específico. No se almacenan totales ni promedios en la tabla de hechos; toda agregación se realiza en tiempo de consulta.

1.2 Resumen de tablas

Tabla	Tipo	Columnas clave	SCD	Fuente
fact_despacho	Hechos	id_despacho (PK)	—	F1 (CSV sintético)
dim_tiempo	Dimensión	id_tiempo (PK)	Tipo 1	Generada en ETL
dim_producto	Dimensión	id_producto (PK)	Tipo 1	F2 (Excel) + F3 INE
dim_destino	Dimensión	id_destino (PK)	Tipo 1	F1 + F3 INE 8.2.2
dim_exportador	Dimensión	id_exportador (PK)	Tipo 2	F1 (CSV sintético)

1.3 Diagrama del esquema estrella

A continuación se presenta el diagrama del modelo dimensional:



1.4 Dimensión con SCD Tipo 2: dim_exportador

La dimensión dim_exportador implementa Slowly Changing Dimension Tipo 2. La justificación es que los atributos de un exportador — razón social, departamento de operación y tipo de empresa — pueden cambiar a lo largo del tiempo (fusiones, cambios de domicilio fiscal, reconversión societaria). Con SCD Tipo 2 se mantiene el historial completo: cada versión del registro tiene fecha_inicio, fecha_fin y el indicador es_vigente, lo que permite que los hechos históricos sigan apuntando al estado del exportador vigente al momento del despacho.

Las demás dimensiones usan SCD Tipo 1 (sobrescribir) dado que sus atributos no requieren historial: los nombres de países no cambian, los códigos NCM son estables y los atributos de tiempo son inmutables.

1.5 Diccionario de datos — tabla de hechos

Columna	Descripción
id_despacho	Clave primaria surrogate — identificador único del despacho
id_tiempo	FK → dim_tiempo — fecha del despacho
id_producto	FK → dim_producto — producto exportado (código NCM)
id_destino	FK → dim_destino — país de destino
id_exportador	FK → dim_exportador — empresa exportadora (SCD Tipo 2)
fob_usd	Valor FOB del despacho en dólares estadounidenses (USD)
peso_kg	Peso neto de la mercadería en kilogramos
cantidad_bultos	Número de bultos o unidades embarcadas

2. Fuentes de Datos y Staging Area

2.1 Fuentes utilizadas

El proyecto integra tres fuentes heterogéneas de datos:

- F1 — Despachos de exportación (CSV sintético): 5.000 registros generados con Python/Faker, estructurados sobre la nomenclatura real de la Aduana Nacional de Paraguay. Período 2023–2025.
- F2 — Catálogo de productos NCM (Excel .xlsx): 20 productos basados en la nomenclatura MERCOSUR real, con precios de referencia en USD/tonelada. Generado sintéticamente.
- F3 — Anuario Estadístico INE 2021 (5 CSV reales): Datos reales descargados del portal datos.gov.py. Incluye exportaciones por producto, por país de destino, precios internacionales y comercio exterior por capítulo NCM para los años 2020 y 2021.

La incorporación de F3 fue sugerida por el docente como observación al H1 y se justifica porque enriquece el modelo con datos históricos reales que permiten contextualizar y validar los datos sintéticos generados para el período 2023–2025.

2.2 Tablas cargadas en staging

Tabla staging	Filas	Fuente	Descripción
stg_f1_despachos	5.000	F1	Despachos sintéticos de exportación 2023–2025
stg_f2_productos	20	F2	Catálogo de productos NCM/MERCOSUR
stg_f3_exp_producto	26	F3	INE 8.2.1 — Exportaciones por producto y mes
stg_f3_exp_destino	26	F3	INE 8.2.2 — Exportaciones por país y mes
stg_f3_precios_int	26	F3	INE 8.2.3 — Precios internacionales soja/algodón
stg_f3_ncm_2020	90	F3	INE 8.2.8 — Exportaciones por capítulo NCM 2020
stg_f3_ncm_2021	89	F3	INE 8.2.9 — Exportaciones por capítulo NCM 2021

La carga al staging se realizó sin transformaciones: los datos entran tal cual están en los archivos fuente. Esto sigue el principio de staging area como zona de aterrizaje puro, donde se preserva la fuente original antes de aplicar cualquier limpieza o transformación.

2.3 Motor y archivo de base de datos

Concepto	Detalle
Motor	DuckDB 1.5 (archivo único, motor columnar embebido)
Archivo staging	data/staging/staging.duckdb
Archivo DW	data/dw/agroexport.duckdb
Cliente SQL	DBeaver Community 24.x
ETL	Python 3.12 + pandas 2.2 + duckdb 1.5

3. Proceso ETL — Estado Actual

3.1 Descripción del pipeline

El proceso ETL se implementó en cuatro scripts Python versionados en Git:

- gen_f1.py — Genera los 5.000 registros sintéticos de despachos (F1) y los guarda en data/raw/sintetico/f1_despachos.csv.
- gen_f2.py — Genera el catálogo de 20 productos (F2) y lo guarda en data/raw/sintetico/f2_productos.xlsx.
- staging_load.py — Carga F1, F2 y los 5 archivos de F3 al staging DuckDB sin transformaciones.
- etl_dw.py — Transforma y carga desde staging al modelo dimensional: construye las cuatro dimensiones y la tabla de hechos con resolución de claves sustitutas (surrogate keys).

3.2 Control de calidad — hallazgos

Durante la carga a la tabla de hechos se ejecutó una verificación de integridad referencial sobre las claves foráneas. El resultado fue el siguiente:

Concepto	Resultado
Registros fuente (F1)	5.000 despachos
Registros cargados en fact	4.503 despachos (90,1 %)
Registros descartados	497 (9,9 %)
Motivo del descarte	Códigos NCM de F1 sin correspondencia en el catálogo F2 (id_producto nulo tras el join)
id_destino nulos	0 — todos los países resolvieron correctamente
id_exportador nulos	0 — todos los exportadores resolvieron correctamente
Acción tomada	Registros descartados (cuarentena); no se cargaron a fact_despacho

Este hallazgo demuestra que el proceso ETL detecta y filtra registros con integridad referencial rota, cumpliendo con el requisito de control de calidad del enunciado. Los 497 registros descartados representan la diferencia entre los 10 códigos NCM generados en F1 y el subconjunto de esos códigos presente en el catálogo F2. En la entrega final (H3) se corregirá este desajuste para lograr una carga del 100 %.

3.3 Estado del repositorio Git

El repositorio contiene los siguientes commits hasta este avance:

- feat: agrego DDL del esquema dimensional (star schema)
- feat: agrego scripts generadores de datos sintéticos F1 y F2
- feat: staging area cargado en DuckDB (F1, F2, F3)
- feat: ETL cargado al modelo dimensional — 4.503 hechos, 4 dimensiones
- feat: operaciones OLAP implementadas (roll-up, drill-down, slice, dice, pivot)